

4. Lineare Codes

Irren ist menschlich, wer aber auf Irrtümern beharrt, ...

4.1 Error Correcting Codes

Beispiel:

Codewörter: $c_1 = 100110, c_2 = 010101, c_3 = 001011, c_4 = 000000$

Mit Wörtern wollen wir rechnen. Deshalb kommen die Buchstaben aus einem Körper $F = F_q$, q Primzahlpotenz.

Der **Code** C ist die Menge der Codewörter $C \subseteq F_q^n$, n ist die Wortlänge.

obiges Beispiel: $n = 6, q = 2$

ISBN10: $n = 10, q = 11$

$q = 2$: binärer Code, $q = 3$: ternärer Code.

Senden und Empfangen einer Nachricht $a \in F_q^k, k < n$

Codierungsfunktion $\varphi : F_q^k \rightarrow F_q^n, a = a_1 \dots a_k, \varphi(a) = c$

a codieren: $\varphi(a) = c \in C$ Codewort

↓

c senden

↓

← mögliche Fehler

$r \in F_q^n$ empfangen

↓

r decodieren: $r \rightarrow c \in C$ gesendetes Codewort

↓

$a = \varphi^{-1}(c)$ Nachricht

φ injektiv (eindeutig), aber nicht surjektiv.

Fehler **erkennen**: $r \in C$?

Fehler **korrigieren**: $r \rightarrow c$. r auf das nächstgelegene Codewort c abbilden.

c ist unbekannt. Wie kann der Empfänger $r \neq c$ erkennen?

Lösung: Es werden nicht alle Wörter aus F_q^n als Codewörter zugelassen,

$$C \neq F_q^n$$

Beispiel: $C = \{c_1, c_2, c_3, c_4\}$

Zwei Codewörter unterscheiden sich in mindestens 3 Stellen,

d.h. $e < 3$ Fehler werden erkannt.

$r = 010001$ ist kein Codewort.

Unter der Annahme, dass 2 Fehler seltener sind als 1 Fehler, wird das Wort

$$r \rightarrow c_2 = 010101$$

rekonstruiert. y unterscheidet sich in 2 Stellen von c_4 . 2 Fehler kann C nicht korrigieren.

Definieren das **Gewicht** eines Wortes $w \in F_q^n$

$$|w| = |\{i \mid w_i \neq 0\}|$$

Der **Hamming Abstand** $|v-w|$

gibt an, an wie vielen Stellen sich die Wörter $v, w \in F_q^n$ unterscheiden.

Für den Hamming Abstand gelten die **Abstandsregeln:** $v, w, y \in F_q^n$

$$|v-w| = |w-v|$$

Symmetrie

$$|v-w| \geq 0$$

positiv semidefinit

$$|v-w| = 0 \Rightarrow w = v$$

positiv definit

$$|v-w| \leq |v-y| + |y-w|$$

Dreiecksungleichung

Minimalgewicht des Codes C (minimum distance)

$$d_C := \min \{ |c - c'| \mid c, c' \in C, c \neq c' \}$$

Beispiel: Der obige Code C hat das Minimalgewicht $d_C = 3$.

Satz:

Sei e = Anzahl der Fehler im Wort r .

C erkennt das Wort r als falsch $\Leftrightarrow e + 1 \leq d_C$

C korrigiert das Wort $r \rightarrow c \Leftrightarrow 2e + 1 \leq d_C$

Falls $d_C \geq e + 1$ heißt C **e -Fehler-erkennend**;

falls $d_C \geq 2e + 1$ heißt C **e -Fehler-korrigierend**.

Forderungen an einen Code C

- schnelles Codieren:

$$\varphi(a) = c$$

- schnelles Decodieren:

$$r \rightarrow c, \varphi^{-1}(c) = a$$

- viele Fehler korrigierend

d_C groß,

- hohe Informationsdichte.

$$|C| / |F_q^n|$$

Parameter des Codes C

$$[n, |C|, d_C]_q$$

4.2 Lineare Codes

Definition: Der Code C heißt **linear**, wenn $C \subseteq F_q^n$ ein Unterraum von F_q^n ist, d.h. wenn $\mathbf{o} \in C$ und

- (A) $\mathbf{c} + \mathbf{c}' \in C$ für alle $\mathbf{c}, \mathbf{c}' \in C$
 (M) $a \mathbf{c} \in C$ für alle $\mathbf{c} \in C, a \in F_q$

Sei $k = \text{Dim } C$. Dann existieren k l.u. Codewörter $\mathbf{g}_1, \dots, \mathbf{g}_k \in C$.

Die $\mathbf{g}_1, \dots, \mathbf{g}_k$ bilden dann eine Basis von C .

Sei G die (k, n) -Matrix mit den Zeilen $\mathbf{g}_1, \dots, \mathbf{g}_k$.

$$C = \{ a_1 \mathbf{g}_1 + \dots + a_k \mathbf{g}_k \mid a_1, \dots, a_k \in F_q \} = \{ \mathbf{a} G \mid \mathbf{a} \in F_q^k \}$$

$C =$ Zeilenraum von G .

Eine (k, n) -Matrix G mit

$$C = \{ \mathbf{a} G \mid \mathbf{a} \in F_q^k \} \quad \text{und} \quad k = \text{Dim } C = \text{Rang } G$$

heißt **Erzeugermatrix** des Codes C .

Folgerung: $|C| = |F_q^k| = q^k$ □

Jede Nachricht $\mathbf{a} \in F_q^k$ besitzt ein Codewort aus C . Die **Codierungsfunktion**

$$\varphi : F_q^k \rightarrow C \quad \mathbf{a} \rightarrow \mathbf{c} = \mathbf{a} G$$

ist bijektiv.

Parameter des linearen Codes $C : [n, k, d]_q$, $k = \text{Dim } C = \text{Dim } F_q^k$, $d = d_C$.

Informationsdichte bei linearen Codes; k/n .

Wiederholungscode: $\varphi : F_q \rightarrow C, \quad a \rightarrow (a, a, \dots, a) = a (1 \ 1 \ \dots \ 1)$
 $G = (1 \ 1 \ \dots \ 1), \quad d_C = n$

C ist ein $[n, 1, n]_q$ Code.

Informationsdichte $= 1/n = \text{fast } 0\%$ für großes n ,

$d_C = n$, d.h. C korrigiert $\begin{cases} (n-1)/2 \\ n/2-1 \end{cases}$ Fehler, falls $n \begin{cases} \text{ungerade} \\ \text{gerade} \end{cases}$

Paritätscode:

$$\varphi : F_q^{n-1} \rightarrow C, \quad (a_1, \dots, a_{n-1}) \rightarrow (a_1, \dots, a_{n-1}, \sum a_i) = \mathbf{a} \begin{pmatrix} 1 & & & 1 \\ & \ddots & & \vdots \\ & & 1 & 1 \end{pmatrix}, \quad d_C = 2$$

C ist ein $[n, n-1, 2]$ Code, d.h. 1 Fehler erkennend.

Informationsdichte $= (n-1)/n = 1 - 1/n = \text{fast } 100\%$ für großes n ,

$d_C = 2$, d.h. C kann keinen Fehler korrigieren.

Kontrollmatrix für C

Eine $(n-k, n)$ -Matrix H mit

$$C = \text{Kern } H = \{ \mathbf{c} \in F_q^n \mid H \mathbf{c}^T = \mathbf{0} \}$$

H heißt **Kontrollmatrix** für C .

Systematische Form der Kontrollmatrix

$$H = (E_{n-k} \mid A)$$

Systematische Form der Erzeugermatrix

$$G = (-A^T \mid E_k)$$

Es gilt

$$H G^T = O \quad \text{bzw.} \quad G H^T = O$$

Dimensionsformel

$$\text{Rang } G + \text{Rang } H = n, \quad \text{Rang } G = k, \quad \text{Rang } H = n - k$$

Minimalgewicht d_C eines linearen Codes C

$$\begin{aligned} d_C &= \min \{ |\mathbf{c} - \mathbf{c}'| \mid \mathbf{c}, \mathbf{c}' \in C, \mathbf{c} \neq \mathbf{c}' \} \\ &= \min \{ |\mathbf{c}| \mid \mathbf{c} \in C, \mathbf{c} \neq \mathbf{0} \} \end{aligned}$$

$$H \mathbf{c}^T = \mathbf{0} \Rightarrow |\mathbf{c}| \text{ Spalten von } H \text{ sind l.a.}$$

$$\Rightarrow d_C = 1 + \max \{ e \mid \text{jeweils } e \text{ Spalten von } H \text{ sind l.u.} \}$$

Dualitätssatz:

Je s Spalten der Kontrollmatrix H seien l. u. Dann ist schwacher:

$$s + 1 \leq d_C \leq |\mathbf{c}|$$

starker:

$$\max \{s + 1\} = d_C = \min \{ |\mathbf{c}| \mid \mathbf{0} \neq \mathbf{c} \in C \}$$

Man nutzt den Dualitätssatz zur Bestimmung von d_C .

Forderungen an einen Code C

- viele Fehler korrigierend (s, d_C groß),

4.3 Der binäre Hamming Code $H_2(m)$, $F = F_2$

Definition:

Die Spalten der Kontrollmatrix H enthalten die Binärdarstellung der Zahlen
 $1, 2, \dots, n = 2^m - 1$.

m.a.W. ... enthalten sämtliche von Null verschiedene m -Tupel bestehend aus Nullen und Einsen.

Verschiedene Anordnungen der Spalten liefern isomorphe Codes. Hier ist eine systematische Form des Codes.

Beispiel: $H_2(3)$, $n = 2^m - 1 = 7$,

$$H = \begin{pmatrix} 1 & & & 1 & 0 & 1 & 1 \\ & 1 & & 1 & 1 & 1 & 0 \\ & & 1 & 0 & 1 & 1 & 1 \end{pmatrix}, \quad G = \begin{pmatrix} 1 & 1 & 0 & 1 & & & \\ 0 & 1 & 1 & & 1 & & \\ 1 & 1 & 1 & & & 1 & \\ 1 & 0 & 1 & & & & 1 \end{pmatrix} = \begin{pmatrix} g_1 \\ g_2 \\ g_3 \\ g_4 \end{pmatrix}$$

$\underbrace{\hspace{10em}}_{\text{Kontrolle}} \quad \underbrace{\hspace{10em}}_{\text{Information}}$

Bestimmung von d_C $s + 1 \leq d_C \leq |c|$

Je 2 Spalten von H linear unabhängig $\Rightarrow 2 \leq s$

$\Rightarrow 3 \leq s + 1 \leq d_C \leq |g_1| = 3 \Rightarrow d_C = 3$

d.h. $H_2(3)$ ist ein $[7, 4, 3]_2$ Code, $|H_2(3)| = 2^k = 16$, 1-Fehler korrigierend.

Satz:

Die Parameter von $H_2(m)$ sind $[n, k, d]_q = [n=2^m - 1, n - m, 3]_2$.

Kodieren

$$\mathbf{a} = (a_1 \ a_2 \ a_3 \ a_4) \rightarrow \mathbf{c} = \mathbf{a} G = \begin{pmatrix} c_1 & c_2 & c_3 & a_1 & a_2 & a_3 & a_4 \end{pmatrix}$$

$$\text{mit} \quad \begin{aligned} c_1 &= a_1 + a_3 + a_4 \\ c_2 &= a_1 + a_2 + a_3 \\ c_3 &= a_2 + a_3 + a_4 \end{aligned}$$

Dekodieren

$\mathbf{c} \in H_2(m)$ Codewort (gesendet)

$\mathbf{r} \in F_2^n$ empfangenes Wort

$\mathbf{e} = \mathbf{r} - \mathbf{c}$ Fehlerwort

$S(\mathbf{r}) := H \mathbf{r}^T \in F_2^m$ **Syndrom** des Wortes $\mathbf{r}$

1. Fall: $\mathbf{c} = \mathbf{r} \in C \Rightarrow S(\mathbf{r}) = \mathbf{o}$. Die zu den Spalten von E in G gehörenden Stellen in $\mathbf{c}$ enthalten die Nachricht $\mathbf{a}$

$$\mathbf{c} = (c_1 \ \dots \ c_m \mid a_1 \ \dots \ a_k).$$

2. Fall: $\mathbf{e} = \mathbf{r} - \mathbf{c}$ enthält genau 1 Fehler $e_x = 1$ an der Stelle x

$$\mathbf{e} = (0 \ 0 \ \dots \ 1 \ \dots \ 0)$$

$$S(\mathbf{r}) := H \mathbf{r}^T = H \mathbf{c}^T + H \mathbf{e}^T = H \mathbf{e}^T = \mathbf{h}_x = x\text{-te Spalte von } H$$

$$F_2 = \{0, 1\}$$

$\Rightarrow$ Ändern den Buchstaben an der Stelle x von $\mathbf{r}$

$$\mathbf{c} := \mathbf{r} - \mathbf{e} = r_1 \ r_2 \ \dots \ r_x - 1 \ \dots \ r_n$$

Algorithmus

Berechne das Syndrom $S(\mathbf{r}) := H \mathbf{r}^T$

If ($S(\mathbf{r}) = \mathbf{0}$) $\mathbf{c} = \mathbf{r}$;

Else

Ermittle den Spaltenindex x von H mit $S(\mathbf{r}) = \mathbf{h}_x$;

$\mathbf{c} = \mathbf{r} - \mathbf{e}$ // Ändere die Stelle x in $\mathbf{r}$

End If

4.4 Der q -näre Hamming Code $H_q(m)$, $F = F_q$

Wie viele Spalten hat die Kontrollmatrix H von $H_q(m)$, so dass jeweils $s = 2$ Spalten l.u. sind?

Die Punkte der Geraden

$$g_h = \{ \lambda \mathbf{h} \mid \lambda \in F \} \subseteq F^m$$

sind l.a. Die Spalten von H dürfen also höchstens einen Repräsentanten von g_h enthalten. Die $g_h \setminus \{\mathbf{0}\}$ bilden eine Zerlegung von $F^m \setminus \{\mathbf{0}\}$ in **Klassen**. Jede Klasse besitzt $q - 1$ Elemente.

Definition:

Die Spalten von H bestehen aus Repräsentanten $\mathbf{h}$ der 1-dimensionalen Unterräume (Geraden durch $\mathbf{0}$) des Vektorraums F^m .

Anzahl dieser Klassen:

$$n = (q^m - 1) / (q - 1)$$

Beispiel: $H_3(2)$, $F = F_3$


$$n = (3^2 - 1) / (3 - 1) = 4, \quad k = n - m = 4 - 2 = 2, \quad |H_3(2)| = 3^2 = 9$$

Klassen von F^2

$$H = (E \mid A) = \begin{pmatrix} 1 & 0 & 1 & 1 \\ 0 & 1 & 1 & 2 \end{pmatrix}, \quad G = (-A^T \mid E) = \begin{pmatrix} 2 & 2 & 1 & 0 \\ 2 & 1 & 0 & 1 \end{pmatrix}$$

$$2 + 1 \leq s + 1 \leq d_C \leq 3 \quad \Rightarrow \quad d_C = 3$$

d.h. 1- Fehler korrigierend.



Dekodieren in $H_q(m)$

1. Fall: $\mathbf{c} = \mathbf{r} \in C \Rightarrow S(\mathbf{r}) = \mathbf{o}$.

$$\mathbf{c} = (c_1 \dots c_m \mid a_1 \dots a_k).$$

2. Fall: $\mathbf{e} = \mathbf{r} - \mathbf{c}$ enthält genau 1 Fehler e_x an der Stelle x

$$\mathbf{e} = (0 \dots e_x \dots 0)$$

$$\Rightarrow S(\mathbf{r}) := H \mathbf{r}^T = H \mathbf{e}^T = \mathbf{h}_x e_x$$

$$\Rightarrow \mathbf{c} = \mathbf{r} - \mathbf{e} = r_1 \dots r_x - e_x \dots r_n \quad \text{d.h. } e_x \text{ vom } x\text{-ten Element subtrahieren.}$$

Am schnellsten findet man Fehlerstelle x und Fehlergröße e_x , wenn das erste von Null verschiedene Element in jeder Spalte von H eine 1 ist.

Solche Repräsentanten der Klassen heißen **Klassenführer**.

Algorithmus

Berechne das Syndrom $S(\mathbf{r}) := H \mathbf{r}^T$

If ($S(\mathbf{r}) = \mathbf{o}$) $\mathbf{c} = \mathbf{r}$;

Else

Ermittle den Spaltenindex x von H mit $H \mathbf{e}^T = \mathbf{h}_x e_x$;

$$\mathbf{c} = \mathbf{r} - \mathbf{e}$$

End If

Beispiel: $H_3(2)$, $\mathbf{r}_1 = 1111$, $\mathbf{r}_2 = 0011$

$$S(\mathbf{r}_1) = H \mathbf{r}_1^T = \begin{pmatrix} 0 \\ 1 \end{pmatrix} = \mathbf{h}_2 \Rightarrow x = 2, e_2 = 1 \Rightarrow \mathbf{c}_1 = 1011$$

$$S(\mathbf{r}_2) = H \mathbf{r}_2^T = \begin{pmatrix} 2 \\ 0 \end{pmatrix} = \mathbf{h}_1 2 \Rightarrow x = 1, e_1 = 2 \Rightarrow \mathbf{c}_2 = 1011$$

4.5 Schranken für die Anzahl $|C|$ der Codewörter

Der Code $C \subseteq F_q^n$ korrigiere e Fehler, d.h. $2e + 1 \leq d_C$.

Gesucht: $|C| \leq$ obere Schranke

Kugel um c mit Radius e (Ball)

$$B(e) := \{ v \in F_q^n \mid |c - v| \leq e \}.$$

Die Kugeln $B(e)$ um die $|C|$ Codewörter dürfen sich nicht überschneiden.

$$\Rightarrow |C| \cdot |B(e)| \leq |F_q^n| = q^n$$

$$|B(e)| = \sum_{i=0}^e |\{ v \in F_q^n \mid |c - v| = i \}|$$

Anzahl der Wörter mit Abstand i von $c = c_1 c_2 \dots c_n$

$$|\{ v \in F_q^n \mid |c - v| = 0 \}| = 1$$

$$|\{ v \in F_q^n \mid |c - v| = 1 \}| = n(q - 1)$$

Es gibt n Stellen an denen sich c, v unterscheiden können.

An jeder Stelle von v können $q - 1$ verschiedene Buchstaben stehen.

Analog

$$|\{ v \in F_q^n \mid d(c, v) = 2 \}| = \binom{n}{2} (q - 1)^2$$

Allgemein

$$|\{ v \in F_q^n \mid d(c, v) = i \}| = \binom{n}{i} (q - 1)^i$$

$$\Rightarrow |B(e)| = \sum_{i=0}^e \binom{n}{i} (q - 1)^i$$

$$\textbf{Hamming-Schranke} \quad |C| \cdot \sum_{i=0}^e \binom{n}{i} (q - 1)^i \leq q^n$$

Gilt in dieser Ungleichung "=", dann sind die "Zwischenräume" zwischen den Kugeln $B(e)$ leer. So ein Code C heißt **perfekt**.

Beispiel: $C = H_2(m)$ ist ein $[n, n - m, 3]_2$ Code.

$$n = 2^m - 1, \quad e = 1, \quad q = 2$$

$$|C| = 2^k = 2^{n-m}, \quad \sum_{i=0}^e \binom{n}{i} (q-1)^i = 1 + n = 2^m$$

$$\Rightarrow |C| \cdot \sum_{i=0}^e \binom{n}{i} (q-1)^i = 2^{n-m} \cdot 2^m = 2^n \quad \square$$

Satz:

Sämtliche Hamming Codes $H_q(m)$ sind perfekt.

Bemerkung:

Es gibt nur wenige perfekte Codes,

- die trivialen Codes $C = \{\mathbf{0}\}$, $C = F_q^n$
- die ungeraden binären Wiederholungscodes $[2m+1, 1, 2m+1]_2$
- die Hamming Codes $H_q(m)$
- binäre Golay Code $[23, 12, 7]_2$
- ternäre Golay Code $[11, 6, 5]_3$

Die Singleton-Schranke

Sei C ein (nicht notwendig linearer) $[n, k, d]_q$ Code. Entferne aus jedem $\mathbf{c} \in C$ die letzten $d-1$ Buchstaben. Die Restwörter sind dann immer noch voneinander verschieden.

$$\Rightarrow |C| \leq q^{n-d+1}$$

Falls C linear ist, also $|C| = q^k$ vereinfacht sich das zu

$$k + d \leq n + 1$$

Ein Code, der die Singleton-Schranke mit "=" erfüllt, heißt **MDS-Code** (maximum distance separable).